

sapienzalogo.pdf

## Segmentazione di immagini e analisi geometrica per la classificazione di lesioni cutanee

Facoltà di Matematica

Laurea Triennale in Scienze matematiche per l'intelligenza artificiale

**Aurora Di Giovanna**

Matricola 2127738

Relatrice

Dott.<sup>ssa</sup> Federica Baccini

Anno Accademico 2025/2026

---

**Segmentazione di immagini e analisi geometrica per la classificazione di lesioni cutanee**

Tesi compilativa. Sapienza Università di Roma

© 2026 Aurora Di Giovanna. Tutti i diritti riservati

Questa tesi è stata composta con L<sup>A</sup>T<sub>E</sub>X e la classe Sapthesis.

Email dell'autore: [auroradigiovanna@gmail.com](mailto:auroradigiovanna@gmail.com)

*A mia sorella Ilaria,  
la mia persona, la mia complice.  
È per te ogni cosa che c'è.*

*«Vorrei che portassimo ferri da stiro sulla testa per impedirci di crescere.  
Ma disgraziatamente i boccioli diventano rose e i gattini gatti!»  
Piccole donne*

## Sommario

**Contesto** Il melanoma cutaneo rappresenta una delle neoplasie maligne più aggressive, per la quale la diagnosi precoce costituisce il fattore determinante ai fini della salute del paziente. Nella pratica clinica, la valutazione dermoscopica si avvale della celebre regola euristica ABCD (Asimmetria, Bordi, Colore, Diametro). Tuttavia, l'intrinseca soggettività dell'ispezione visiva ha guidato lo sviluppo di sistemi di diagnosi assistita da calcolatore (*Computer-Aided Diagnosis* – CAD). L'esigenza attuale in ambito clinico richiede strumenti trasparenti ed interpretabili, capaci di superare i limiti di opacità decisionale tipici dei modelli *deep learning* di tipo *black-box*.

**Obiettivi** Il presente lavoro di tesi si propone di progettare, implementare e validare una pipeline computazionale per la diagnosi assistita del melanoma cutaneo sul dataset di riferimento internazionale ISIC 2017. L'obiettivo primario risiede nella trasposizione matematica rigorosa dei criteri morfologici e geometrici della regola ABCD in indici quantitativi invarianti per rototraslazione, in grado di alimentare modelli di Machine Learning spiegabili per la classificazione binaria tra lesioni benigne e malignità.

**Metodi** A partire dalle maschere di segmentazione di riferimento (*Ground Truth*) e dal confronto con algoritmi di segmentazione avanzati, è stata sviluppata una pipeline di estrazione feature basata sui momenti centrali del secondo ordine. Tale formulazione ha consentito l'allineamento spaziale della lesione lungo l'asse principale d'inerzia ed il calcolo del *fitting* ellittico ai minimi quadrati. Sono stati formalizzati descrittori quantitativi dell'irregolarità del bordo ed un indice percentuale di asimmetria basato su rotocompensazione ed operatore logico XOR ( $\oplus$ ). La significatività statistica delle metriche è stata convalidata mediante il test non parametrico di Mann–Whitney  $U$ . Le feature con reale potere selettivo sono state successivamente impiegate per addestrare cinque classificatori di Machine Learning (Regressione Logistica, Albero Decisionale, Random Forest, Bagging e Gradient Boosting) valutati in *5-Fold Stratified Cross-Validation* con pesatura asimmetrica delle classi (*Class Weighting* 4:1 a tutela della sensibilità clinica).

**Risultati** L'analisi statistica ha confermato la forte capacità discriminante del discostamento ellittico  $m$ , dell'indice di compattezza  $I_a$  e dell'asimmetria globale ( $p < 10^{-10}$ ). Nella fase di classificazione, la Regressione Logistica ha mostrato la miglior capacità separabile complessiva (ROC-AUC = 0,7088, Accuracy = 69,00%, Recall = 55,09% sul melanoma), dimostrando come modelli lineari lisci su feature compatte evitino i fenomeni di *overfitting* tipici degli algoritmi ad albero. L'Albero Decisionale ha invece massimizzato la sensibilità di *screening* (Recall = 70,03%, riducendo al minimo i falsi negativi). Il sistema validato offre un ausilio diagnostico a costo computazionale minimo, istantaneo e pienamente interpretabile per il personale sanitario.

# Indice

|          |                                                                                               |           |
|----------|-----------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduzione</b>                                                                           | <b>1</b>  |
| 1.1      | Le lesioni cutanee ed il melanoma: Diagnosi precoce . . . . .                                 | 1         |
| 1.2      | La dermatoscopia e la regola clinica ABCD . . . . .                                           | 1         |
| 1.3      | Sistemi CAD (Computer-Aided Diagnosis) . . . . .                                              | 2         |
| 1.3.1    | Le criticità nei sistemi CAD: Propagazione degli errori e<br>sbilanciamento clinico . . . . . | 2         |
| 1.4      | Stato dell'arte e lavori pregressi . . . . .                                                  | 3         |
| 1.4.1    | Evoluzione dei modelli di segmentazione di immagini biomediche                                | 3         |
| 1.4.2    | Il ruolo della classificazione nella diagnosi assistita . . . . .                             | 5         |
| 1.5      | Obiettivi . . . . .                                                                           | 5         |
| 1.6      | Struttura dell'elaborato . . . . .                                                            | 5         |
| <b>2</b> | <b>Segmentazione di lesioni cutanee</b>                                                       | <b>7</b>  |
| 2.1      | Il ruolo della segmentazione nei sistemi CAD . . . . .                                        | 7         |
| 2.1.1    | Generazione delle maschere nel dataset ISIC 2017 . . . . .                                    | 7         |
| 2.2      | Confronto tra metodologie di segmentazione . . . . .                                          | 8         |
| 2.2.1    | Segmentazione tramite SkinMamba . . . . .                                                     | 8         |
| 2.2.2    | Segmentazione tramite GrabCut . . . . .                                                       | 11        |
| 2.2.3    | Valutazione delle prestazioni di GrabCut . . . . .                                            | 13        |
| 2.3      | Analisi qualitativa e differenze principali tra i due approcci . . . . .                      | 13        |
| <b>3</b> | <b>Analisi geometrica e statistica delle lesioni cutanee</b>                                  | <b>15</b> |
| 3.1      | Dataset ISIC 2017 e preparazione dei dati . . . . .                                           | 15        |
| 3.2      | Estrazione delle caratteristiche geometriche . . . . .                                        | 16        |
| 3.2.1    | Metrica di discostamento ellittico . . . . .                                                  | 16        |
| 3.2.2    | Indici di Irregolarità del bordo . . . . .                                                    | 18        |
| 3.2.3    | Quantificazione dell'asimmetria . . . . .                                                     | 18        |
| 3.3      | Risultati dell'Estrazione . . . . .                                                           | 19        |
| 3.4      | Analisi statistica delle feature geometriche . . . . .                                        | 20        |
| 3.4.1    | Test statistico di Mann-Whitney . . . . .                                                     | 21        |
| 3.4.2    | Interpretazione del p-value . . . . .                                                         | 21        |
| 3.4.3    | Risultati del test statistico . . . . .                                                       | 23        |
| 3.4.4    | Rappresentazione tramite diagrammi scatola e baffi . . . . .                                  | 23        |

---

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| <b>4</b> | <b>Classificazione</b>                                   | <b>25</b> |
| 4.1      | Caratteristiche del dataset e pre-elaborazione . . . . . | 25        |
| 4.2      | Addestramento e validazione . . . . .                    | 25        |
| 4.3      | Algoritmi a confronto . . . . .                          | 26        |
| <b>5</b> | <b>Conclusione</b>                                       | <b>32</b> |
| 5.1      | Sviluppi futuri . . . . .                                | 33        |
|          | <b>Bibliografia</b>                                      | <b>35</b> |
|          | Figure . . . . .                                         | 37        |
|          | <b>Ringraziamenti</b>                                    | <b>37</b> |

# Elenco delle figure

|     |                                                                                                                                                                                                                                                                                                                        |    |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Immagine dermoscopia originale del dataset ISIC 2017. . . . .                                                                                                                                                                                                                                                          | 8  |
| 2.2 | Maschera binaria <i>Ground Truth</i> corrispondente fornita da ISIC 2017. . . . .                                                                                                                                                                                                                                      | 8  |
| 2.3 | Architettura SkinMamba, tratta da [3]. . . . .                                                                                                                                                                                                                                                                         | 10 |
| 2.4 | Architettura del grafo orientato <i>S-T</i> ed ottimizzazione del taglio minimo nell'algoritmo GrabCut (Immagine riadattata da <i>Scaler Topics</i> [5]). . . . .                                                                                                                                                      | 12 |
| 2.5 | Confronto visivo tra i metodi di segmentazione su 4 campioni rappresentativi del dataset: (1) Immagine dermoscopia originale RGB, (2) Maschera binaria generata da <i>GrabCut</i> , (3) Maschera generata dalla rete neurale profonda <i>SkinMamba</i> , (4) Maschera di riferimento <i>Ground Truth</i> ISIC. . . . . | 14 |
| 3.1 | A sinistra troviamo il grafico per categoria specifica. A destra troviamo la divisione tra benigno (Nevi + Cheratosi) e maligno. . . . .                                                                                                                                                                               | 16 |
| 3.2 | Istogrammi di distribuzione delle feature condizionati alla classe diagnostica. . . . .                                                                                                                                                                                                                                | 20 |
| 3.3 | Diagrammi scatola e baffi degli indici geometrici confrontati tra lesioni benigne e melanomi. . . . .                                                                                                                                                                                                                  | 24 |
| 4.1 | Matrice di confusione ottenuta per il classificatore <i>Decision tree</i> . . . . .                                                                                                                                                                                                                                    | 31 |
| 4.2 | Matrice di confusione per il classificatore <i>Bagging</i> . . . . .                                                                                                                                                                                                                                                   | 31 |
| 4.3 | Matrice di confusione per il classificatore <i>Gradient boosting</i> . . . . .                                                                                                                                                                                                                                         | 31 |
| 4.4 | Matrice di confusione per il classificatore <i>Regressione logistica</i> . . . . .                                                                                                                                                                                                                                     | 31 |
| 4.5 | Matrice di confusione per il classificatore <i>Random forest</i> . . . . .                                                                                                                                                                                                                                             | 31 |

# Elenco delle tabelle

|     |                                                                                                                      |    |
|-----|----------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Suddivisione del dataset ISIC 2017 per categoria specifica. . . . .                                                  | 15 |
| 3.2 | Suddivisione binaria utilizzata nell'analisi statistica. . . . .                                                     | 16 |
| 3.3 | Riassunto statistico delle feature morfologiche. . . . .                                                             | 20 |
| 3.4 | Risultati del test statistico Mann–Whitney per ogni indice geometrico. . . . .                                       | 23 |
| 4.1 | Risultati di classificazione dettagliati per classe con metriche globali<br>(5-Fold Cross-Validation). . . . .       | 28 |
| 4.2 | Risultati di classificazione aggregati a livello globale (Weighted vs<br>Macro) con 5-Fold Cross-Validation. . . . . | 29 |

# Capitolo 1

## Introduzione

### 1.1 Le lesioni cutanee ed il melanoma: Diagnosi precoce

In ambito dermatologico, secondo la classificazione teorica proposta da Shetty et al. [6], una lesione cutanea è definita come un'alterazione morfologica della pelle che presenta caratteristiche anomale rispetto al tessuto cutaneo circostante. Tali lesioni si distinguono in due categorie principali:

- **Lesioni Primarie:** condizioni anomale che si sviluppano nel tempo o presenti fin dalla nascita (quali nevi pigmentati, cheratosi e melanomi). I
- **Lesioni Secondarie:** alterazioni che derivano dall'evoluzione, dal trauma o dall'esacerbazione di lesioni primarie (ad esempio croste o erosioni derivanti da sfregamento).

Indipendentemente dalla loro apparenza iniziale, alcune tipologie di lesioni cutanee nascondono una natura altamente pericolosa ed aggressiva, indicando la presenza di neoplasie maligne che richiedono un immediato intervento chirurgico. Il melanoma è il tipo di cancro cutaneo più pericoloso, in quanto, una volta progredito, presenta un tasso di mortalità estremamente elevato. Tuttavia, se individuato nelle sue fasi iniziali, risulta curabile. Di conseguenza, una diagnosi precoce ed accurata delle lesioni cutanee è fondamentale per salvaguardare la salute del paziente.

### 1.2 La dermatoscopia e la regola clinica ABCD

Per superare i limiti dell'ispezione visiva ad occhio nudo, la pratica clinica moderna si avvale della dermatoscopia. Tale tecnica non invasiva impiega un dispositivo ottico manuale (dermatoscopio) che, combinando ingrandimenti ottici e luce polarizzata o liquidi di immersione, annulla la riflessione della luce sullo strato corneo rendendo trasparenti gli strati superficiali dell'epidermide. In questo modo il dermatologo può osservare le strutture pigmentate e vascolari sottocutanee non visibili a occhio nudo [13].

Per standardizzare l'interpretazione visiva delle lesioni, la letteratura ha introdotto la regola ABCD [17], un algoritmo euristico basato su quattro criteri morfologici primari:

- **A - Asimmetria (Asymmetry):** valuta se la lesione, divisa da due assi ortogonali passanti per il suo centroide, presenta forma e distribuzione cromatica disomogenee nei quattro quadranti.
- **B - Irregolarità dei bordi (Border irregularity):** analizza i margini della lesione, rilevando tagli, rientranze o contorni frastagliati ed indistinti [11].
- **C - Variabilità cromatica (Color variation):** rileva la presenza di molteplici tonalità cromatiche all'interno della stessa lesione (nero, marrone scuro, marrone chiaro, bianco, rosso, blu-grigio).
- **D - Diametro (Diameter / Differential structures):** considera lesioni con diametro maggiore di 6 mm o presenza di strutture dermoscopiche differenziali atipiche.

Tra questi quattro parametri, l'asimmetria (A) e l'irregolarità del bordo (B) costituiscono le componenti morfologico-geometriche fondamentali per distinguere un nevo benigno da un melanoma iniziale [11].

### 1.3 Sistemi CAD (Computer-Aided Diagnosis)

La necessità di rendere la diagnosi precoce più affidabile, riproducibile e accessibile ha guidato negli ultimi anni l'evoluzione dei sistemi di diagnosi assistita da calcolatore (**Computer-Aided Diagnosis – CAD**). L'obiettivo primario di un sistema CAD in dermatologia è l'affiancamento del medico come strumento di secondo parere, capace di estrarre evidenze oggettive e ridurre l'impatto di errori diagnostici. Una pipeline computazionale CAD per immagini dermoscopiche comprende quattro stadi fondamentali:

1. **Pre-elaborazione:** rimozione di artefatti superficiali (quali peli, bolle, riflessi luminosi e vignettatura scura periferica introdotta dalle lenti del dermatoscopio).
2. **Segmentazione della lesione:** isolamento della regione di interesse (*Region of Interest* – ROI) dal tessuto cutaneo sano circostante mediante generazione di una maschera binaria.
3. **Estrazione e selezione delle feature:** traduzione matematica delle proprietà visive e geometriche della lesione (conformi alla regola ABCD) in parametri scalari invarianti per scala e rotazione.
4. **Classificazione:** impiego di modelli statistici o di machine learning per categorizzare la lesione.

#### 1.3.1 Le criticità nei sistemi CAD: Propagazione degli errori e sbilanciamento clinico

La progettazione di sistemi CAD operanti su dati clinici reali presenta due sfide:

- **Sensibilità alla qualità del contorno:** le metriche morfologiche (area, perimetro, deviazione ellittica, asimmetria) dipendono strettamente dalla fedeltà della maschera di segmentazione.
- **Sbilanciamento delle classi:** nella realtà e nei dataset dermatoscopici pubblici (come il dataset ISIC 2017 <sup>1</sup>[8]), le lesioni benigne superano ampiamente i casi confermati di melanoma. I tradizionali algoritmi di machine learning (Random forest, Regressione logistica, SVM) tendono a minimizzare l'errore globale ottimizzando la classe maggioritaria, con il conseguente aumento di falsi negativi (tumori maligni etichettati come benigni). In ambito medico, il falso negativo rappresenta l'errore più critico; risulta quindi indispensabile adottare strategie di penalizzazione asimmetrica (*Class Weighting*).

## 1.4 Stato dell'arte e lavori progressi

La letteratura scientifica sull'analisi automatica delle lesioni cutanee ha visto un'intensa attività di ricerca, tra metodologie basate su feature geometrico-statistiche e modelli guidati dal *deep learning*. La disponibilità di dataset aperti e standardizzati ha rappresentato il fattore abilitante per lo sviluppo dei moderni sistemi CAD. I lavori pionieristici di Codella et al. [8], nell'ambito delle competizioni annuali organizzate da ISIC, hanno introdotto dataset su larga scala contenenti migliaia di immagini dermoscopiche corredate da maschere binarie di *Ground Truth* validate da team di dermatologi esperti e diagnosi istopatologiche confermate. Il dataset ISIC 2017 costituisce il punto di riferimento internazionale impiegato nel presente studio.

### 1.4.1 Evoluzione dei modelli di segmentazione di immagini biomediche

La segmentazione accurata della lesione costituisce la base per qualsiasi analisi morfologica affidabile. Nella loro rassegna, Yao et al. [2] hanno tracciato l'evoluzione storica dei modelli di segmentazione in ambito medico, evidenziando il passaggio dalle prime architetture convoluzionali fino ai più recenti modelli basati su Transformer. Come evidenziato nell'analisi di Yao et al. [2], un primo importante passo è rappresentato dalle *Fully Convolutional Networks* (FCN), che hanno introdotto la possibilità di utilizzare reti convoluzionali per produrre direttamente una predizione a livello di pixel. A differenza delle tradizionali reti di classificazione, le FCN sostituiscono gli strati completamente connessi con operazioni convoluzionali, permettendo di preservare la struttura spaziale dell'immagine e di ottenere una mappa di segmentazione. Tuttavia, le operazioni di *pooling* comportano una perdita di dettagli spaziali, particolarmente importante quando è necessario individuare con precisione i contorni delle strutture da segmentare. Una successiva evoluzione, evidenziata dagli autori [2], è rappresentata dalla *U-Net*, introdotta da Ronneberger et al. [10], che è diventata una delle architetture di riferimento per la segmentazione delle immagini biomediche. La rete presenta una struttura *encoder-decoder*: la parte di *encoder* riduce progressivamente la risoluzione dell'immagine per estrarre

<sup>1</sup>Link al dataset: <https://challenge.isic-archive.com/landing/2017/>

caratteristiche sempre più astratte, mentre il *decoder* ricostruisce progressivamente la risoluzione originale producendo la maschera di segmentazione. Un elemento caratterizzante è costituito dalle *skip connections* <sup>2</sup>, che collegano direttamente i livelli dell'encoder con quelli corrispondenti del decoder. In questo modo è possibile combinare le informazioni semantiche estratte a bassa risoluzione con i dettagli spaziali presenti alle risoluzioni più elevate, migliorando la localizzazione dei bordi e delle strutture di interesse. Successivamente sono state sviluppate numerose varianti della U-Net con l'obiettivo di migliorare la capacità della rete di rappresentare strutture caratterizzate da dimensioni e forme differenti. Tra queste, Yao et al. [2] considerano, ad esempio, *DeepLab* e *UNet++*. DeepLab introduce l'utilizzo delle convoluzioni dilatate <sup>3</sup>, che consentono di aumentare il campo recettivo della rete senza dover ridurre ulteriormente la risoluzione delle feature map. Questo permette di incorporare informazioni provenienti da regioni più ampie dell'immagine mantenendo una buona capacità di localizzazione. UNet++, invece, modifica la struttura delle connessioni tra encoder e decoder attraverso percorsi più densi e connessioni intermedie, con l'obiettivo di ridurre il divario semantico tra le caratteristiche provenienti dai diversi livelli della rete. Nonostante i notevoli risultati dalle architetture basate su convoluzioni, tali operazioni presentano una caratteristica intrinseca: le convoluzioni elaborano principalmente informazioni locali. Per rappresentare relazioni tra regioni dell'immagine molto distanti tra loro è quindi necessario utilizzare architetture profonde o meccanismi specifici per ampliare il campo recettivo. Questo limite ha motivato l'introduzione dei *Transformer* anche nel campo della visione artificiale. Il meccanismo di *self-attention* permette infatti di modellare direttamente le relazioni tra differenti regioni dell'immagine, consentendo di catturare dipendenze a lungo raggio. In questo contesto si collocano architetture come *TransUNet*, che combina la capacità di estrazione delle caratteristiche locali proprie delle CNN con la capacità dei Transformer di modellare relazioni globali, e *Swin-Unet*, che utilizza il paradigma dello *Swin Transformer* all'interno di una struttura di tipo U-Net. Questi modelli rappresentano un ulteriore passaggio nell'evoluzione della segmentazione medica, introducendo meccanismi in grado di considerare il contesto globale dell'immagine oltre alle caratteristiche locali.

Un ulteriore sviluppo è rappresentato da modelli progettati per essere applicabili a una maggiore varietà di immagini. Tra questi rientra il *Segment Anything Model* (SAM) [1, 2], proposto per la segmentazione generica attraverso l'utilizzo di differenti modalità di *prompt*. L'introduzione di questi modelli evidenzia il progressivo passaggio da architetture specializzate verso sistemi caratterizzati da una maggiore capacità di generalizzazione.

L'evoluzione descritta mostra quindi un progressivo spostamento dell'attenzione dalla sola estrazione di caratteristiche locali alla necessità di modellare efficacemente anche le dipendenze a lungo raggio, mantenendo un costo computazionale compatibile con l'elaborazione di immagini ad alta risoluzione. In questo contesto si inseriscono le architetture più recenti basate sugli *State Space Models* (SSM), e in

<sup>2</sup>Una skip connection è un collegamento in una rete neurale che salta uno o più strati (layer), passando l'input direttamente a un livello successivo tramite somma o concatenazione.

<sup>3</sup>Una convoluzione dilatata è un'operazione di deep learning che inserisce degli spazi vuoti tra gli elementi del filtro, permettendo di ampliare il campo visivo del modello senza aumentare il numero di parametri.

particolare il paradigma *Mamba* [3]. Questi modelli mirano a combinare la capacità di rappresentare dipendenze a lungo raggio con una complessità computazionale più contenuta rispetto ai meccanismi di attenzione. Tale evoluzione costituisce il contesto teorico nel quale si colloca *SkinMamba* [3], utilizzato nel presente lavoro per la segmentazione delle lesioni cutanee.

#### 1.4.2 Il ruolo della classificazione nella diagnosi assistita

La fase di classificazione rappresenta la fase in cui le informazioni estratte dall'immagine vengono tradotte in una decisione. In ambito dermoscopico, l'obiettivo principale consiste nel discriminare le lesioni maligne (morfologicamente irregolari, come il melanoma) da quelle benigne (come nevi e cheratosi seborroiche) [6].

Mentre le reti neurali profonde tendono a classificare le immagini in modo *end-to-end* elaborando direttamente i pixel grezzi, la letteratura evidenzia l'efficacia dei paradigmi di machine learning supervisionato alimentati da feature esplicite [13]. Algoritmi quali Random Forest, Gradient Boosting, Support Vector Machines (SVM) e Regressione Logistica consentono di mappare gli indici geometrici e di irregolarità della lesione in uno spazio decisionale altamente discriminativo [13, 7]. Questo approccio evita le black-box delle reti profonde, garantendo la spiegabilità clinica delle predizioni e limitando l'overfitting grazie all'uso di pochi descrittori mirati.

### 1.5 Obiettivi

Il presente lavoro di tesi si pone l'obiettivo generale di progettare, sviluppare e validare una pipeline computazionale per la diagnosi assistita (CAD) del melanoma cutaneo, incentrata sulla traduzione matematica dei criteri morfologici e geometrici della regola clinica ABCD. A differenza dei modelli *deep learning* di tipo *black-box*, il cui processo decisionale risulta di difficile interpretazione, questo studio mira a realizzare un sistema trasparente e direttamente verificabile, in cui ogni predizione sia riconducibile a quantificazioni numeriche della forma, del contorno e dell'asimmetria lesionale.

### 1.6 Struttura dell'elaborato

La tesi si articola in cinque capitoli principali. Successivamente al presente capitolo introduttivo, il capitolo 2 illustra il ruolo centrale della segmentazione nei sistemi CAD, dettagliando l'architettura deep *SkinMamba* e l'algoritmo *GrabCut*, corredati da un confronto quantitativo e qualitativo sul dataset ISIC 2017 in presenza di artefatti (peli e vignettatura). Il capitolo 3 descrive la pipeline di estrazione delle feature geometriche e presenta i risultati della validazione statistica condotta tramite il test di Mann-Whitney *U*. Il capitolo 4 approfondisce la fase di pre-elaborazione, l'adozione dei *Class Weights* per contrastare lo sbilanciamento campionario e l'analisi comparativa dei cinque classificatori mediante metriche per classe, metriche aggregate (pesate e macro) e matrici di confusione. Il capitolo 5 riassume le evidenze emerse evidenziando i punti di forza e i limiti intrinseci del sistema sviluppato, delineando

le prospettive future per l'integrazione di descrittori di colore, texture e moduli di inpainting automatico.

## Capitolo 2

# Segmentazione di lesioni cutanee

### 2.1 Il ruolo della segmentazione nei sistemi CAD

La segmentazione delle immagini dermoscopiche rappresenta la prima fase all'interno di un sistema di diagnosi assistita da calcolatore (*CAD*) [11]. Questo processo ha lo scopo di isolare la lesione cutanea, la nostra regione di interesse, dal tessuto cutaneo sottostante. Nelle immagini dermoscopiche reali, sono presenti molteplici fonti di rumore, quali peli e bolle. La segmentazione deve eliminare queste fonti di rumore per fornire solamente la morfologia della lesione cutanea di interesse. Questa fase è determinante per l'intero processo di analisi e classificazione, in quanto l'estrazione delle metriche, in particolare quelle geometriche, come verrà approfondito nel terzo capitolo, dipendono dal bordo e dall'area estratti da tale immagine. Qualsiasi imprecisione, come l'esclusione di una parte della lesione, compromette le metriche e successivamente la classificazione. Dalla segmentazione otteniamo le maschere relative alle nostre immagini. Le maschere associano ad ogni immagine dermoscopia una matrice binaria  $M(x, y)$ :

- **Pixel a valore 0 (nero)** : sfondo e cute sana;
- **Pixel a valore 255 (bianco)** : regione appartenente alla lesione.

#### 2.1.1 Generazione delle maschere nel dataset ISIC 2017

Per la valutazione degli esperimenti ci si è avvalsi delle maschere di riferimento (*Ground Truth*) fornite dal dataset ISIC 2017 [8]. Tali maschere sono state create ed approvate da clinici esperti attraverso due modalità [8]:


1. **Procedura semi-automatica:** avviata da un *seed point* fornito dall'utente, seguito da un algoritmo di *flood-fill* <sup>1</sup> regolato dall'utente e da operazioni di filtraggio morfologico per definire accuratamente i bordi.

---


<sup>1</sup>L'algoritmo di *flood-fill* è un metodo di elaborazione delle immagini che identifica e riempie regioni connesse di pixel a partire da un punto di innesco (*seed*), utilizzato in questo contesto per eliminare vuoti o buchi interni alla maschera binaria della lesione.

2. **Procedura manuale con polilinee**<sup>2</sup>: eseguita mediante il tracciamento puntuale del perimetro lesionale attraverso una serie di punti polilineari posizionati manualmente dall'esperto.

In Figura 2.1 viene mostrato un esempio rappresentativo del dataset ISIC 2017, affiancando l'immagine dermoscópica originale alla relativa maschera binaria *Ground Truth* generata dai dermatologi.



**Figura 2.1** Immagine dermoscópica originale del dataset ISIC 2017.



**Figura 2.2** Maschera binaria *Ground Truth* corrispondente fornita da ISIC 2017.

Questo dataset include anche maschere pre-calcolate a superpixel, intese come rappresentazioni intermedie per algoritmi di segmentazione a grafi. Tali file sono stati filtrati nel preprocessing per lavorare direttamente sulle maschere binarie ad alta risoluzione.

## 2.2 Confronto tra metodologie di segmentazione

### 2.2.1 Segmentazione tramite SkinMamba

Tra i metodi considerati per la generazione automatica delle maschere di segmentazione è stato utilizzato *SkinMamba*, un'architettura di deep learning progettata specificamente per la segmentazione delle lesioni cutanee. Il modello è stato proposto da Zou et al. [3] e il relativo codice sorgente è stato reso disponibile pubblicamente dagli autori<sup>3</sup> [4]. L'implementazione utilizzata nel presente lavoro deriva dal repository ufficiale *SkinMamba*, realizzato in PyTorch [3]. Il metodo è stato valutato dagli autori sui dataset ISIC 2017 e ISIC 2018, risultando adatto al problema della segmentazione delle lesioni cutanee [3].

L'architettura ibrida basata su CNN e Mamba, denominata *SkinMamba*, nasce dall'esigenza di combinare i vantaggi delle reti neurali convoluzionali (*Convolutional Neural Networks*, CNN) con quelli dei modelli basati sui Transformer [3]. Negli ultimi anni, sia le CNN sia le architetture basate sui Transformer sono state ampiamente

<sup>2</sup>Una polilinea è una sequenza di segmenti di linea retta o di archi di cerchio connessi tra loro che il computer o il disegno tecnico considerano come un unico oggetto.

<sup>3</sup>Link al repository github <https://github.com/zs1314/skinmamba>

utilizzate nel campo della segmentazione delle immagini. Le CNN sono particolarmente efficaci nell'estrazione di caratteristiche locali, mentre i Transformer, grazie al meccanismo di *self-attention*, permettono di modellare le relazioni tra regioni anche lontane dell'immagine. Tuttavia, il meccanismo di *self-attention* presenta una complessità computazionale quadratica rispetto al numero  $N$  di elementi dell'input, rendendo il costo computazionale particolarmente elevato all'aumentare della risoluzione dell'immagine. SkinMamba sostituisce quindi il meccanismo di *self-attention* con un modello basato su *State Space Model* (SSM), sfruttando l'architettura Mamba. In questo modo è possibile modellare dipendenze a lungo raggio mantenendo una complessità computazionale lineare  $O(N)$  rispetto al numero di elementi dell'input.

### Architettura del modello

SkinMamba presenta una struttura di tipo encoder-decoder composta da cinque livelli. L'immagine RGB in ingresso viene progressivamente elaborata dall'encoder, nel quale la risoluzione spaziale viene ridotta mediante operazioni di *downsampling*, mentre il numero di canali aumenta. In questo modo la rete estrae caratteristiche a diversi livelli di astrazione. Il decoder esegue il processo inverso, aumentando progressivamente la risoluzione fino a ottenere la maschera di segmentazione finale. L'architettura utilizza inoltre delle *skip connections* tra encoder e decoder, attraverso le quali le caratteristiche estratte ai diversi livelli vengono trasferite direttamente al corrispondente livello del decoder. In SkinMamba queste informazioni vengono combinate mediante una somma elemento per elemento delle rispettive *feature map*, anziché tramite concatenazione come nella U-Net. Questa scelta permette di mantenere invariato il numero di canali della rappresentazione e di evitare l'introduzione di ulteriori parametri dovuti alla fusione delle caratteristiche.


I blocchi della rete combinano operazioni convoluzionali e componenti basate su Mamba. Le convoluzioni consentono di estrarre principalmente caratteristiche locali, come bordi e texture, mentre i moduli Mamba, basati su *State Space Models*, permettono di modellare le dipendenze a lungo raggio con una complessità lineare rispetto alla dimensione dell'input. In particolare, ciascun modulo *Mamba* è strutturato attorno allo *Scale Residual State Space Block* (SRSSB) il quale integra al suo interno due componenti principali:

- il *Visual State Space Block* (VSSB), che permette di catturare dipendenze a lungo raggio <sup>4</sup>;
- lo *Scale-Mixed Feed-Forward Layer* (SMFFL), che sostituisce la rete *Feed-Forward* tradizionale proponendo un'elaborazione multi-scala delle caratteristiche. Attraverso l'impiego di percorsi convoluzionali paralleli con campi ricettivi differenziati, lo SMFFL consente di catturare simultaneamente sia i micro-dettagli ad alta risoluzione (quali le sottili irregolarità dei bordi lesionali) sia le strutture contestuali su scala più ampia.

L'architettura integra inoltre un modulo progettato per migliorare la rappresentazione dei bordi della lesione: il *Frequency Boundary Guided Module* (FBGM). Durante il

<sup>4</sup>Con il termine informazioni a lungo raggio si fa riferimento alle relazioni tra regioni dell'immagine anche spazialmente distanti tra loro, consentendo al modello di considerare la struttura globale della lesione.

processo di *downsampling*, alcune informazioni relative ai contorni possono andare perse. Il FBGM analizza le caratteristiche dell'immagine anche nel dominio della frequenza, dove le alte frequenze sono associate a variazioni rapide come bordi e dettagli. In questo modo il modulo può valorizzare le informazioni relative ai contorni e fornire al decoder indicazioni utili per ottenere una segmentazione più precisa.



**Figura 2.3** Architettura SkinMamba, tratta da [3].

### Generazione delle maschere

Nel repository ufficiale il modello può essere addestrato e successivamente utilizzato per ottenere le predizioni sulle immagini di interesse. Vengono forniti inoltre pesi pre-addestrati di SkinMamba, mentre la configurazione dei parametri di training e testing viene gestita attraverso i file presenti nella cartella **configs**. Il codice è organizzato in modo da produrre i risultati della segmentazione nella directory **outputs** [4].

Nel presente lavoro, l'output della rete viene utilizzato come maschera binaria della regione corrispondente alla lesione cutanea. La maschera rappresenta quindi la separazione tra i pixel appartenenti alla lesione e quelli appartenenti allo sfondo. A partire da tale rappresentazione è successivamente possibile individuare il contorno della regione segmentata e procedere con l'estrazione delle caratteristiche geometriche utilizzate nella fase di analisi.

L'impiego di SkinMamba risulta pertanto funzionale non solo alla localizzazione della lesione, ma all'intera pipeline di analisi descritta nei capitoli successivi. La maschera costituisce infatti il punto di partenza per il calcolo dell'area, del perimetro, dei diametri caratteristici, della deviazione rispetto all'ellisse e degli indici geometrici utilizzati per lo studio della morfologia delle lesioni.

### Valutazione delle prestazioni di SkinMamba

L'architettura *SkinMamba* ha dimostrato capacità di generalizzazione e segmentazione di rilievo sull'intero dataset ISIC 2017, raggiungendo un valore medio di *Dice Similarity Coefficient* (DSC) pari a **89,95%**.

Grazie alla combinazione tra le convoluzioni locali e la modellazione globale a lungo raggio garantita dagli *State Space Models* (VSSB), la rete riesce a ricostruire con estrema precisione anche le morfologie lesionali più complesse, riducendo al minimo sia i falsi positivi sia i falsi negativi rispetto al *Ground Truth* clinico.

### 2.2.2 Segmentazione tramite GrabCut

Uno degli algoritmi principali utilizzati in questo lavoro per la segmentazione automatica è **GrabCut**, introdotto per la prima volta nel 2004 da Rother, Kolmogorov e Blake presso i laboratori della *Microsoft Research Cambridge* [14]. Tale metodo trova un impiego diffuso nella diagnosi assistita di lesioni cutanee [9]. L'algoritmo combina la teoria dei grafi con la modellazione probabilistica del colore.

L'algoritmo è composto dai seguenti passaggi:

#### 1. Inizializzazione della bounding box

La forma originale dell'algoritmo richiede che l'utente specifichi manualmente la bounding box attorno all'oggetto di interesse. Al fine di automatizzare interamente il processo, è stata implementata un'inizializzazione automatica che calcola il rettangolo di selezione mantenendo un margine del 10% lungo i bordi dell'immagine.

```
margin_w = int(W * margin_ratio) # 10% della larghezza
margin_h = int(H * margin_ratio) # 10% dell'altezza
rect = (margin_w, margin_h, W-2 * margin_w, H-2 * margin_h)
```

Tutti i pixel posizionati all'esterno di questo rettangolo vengono classificati a priori come parte dello sfondo cioè cute sana, mentre i pixel situati all'interno del rettangolo vengono considerati come probabile lesione cutanea.

#### 2. Modellazione del colore tramite GMM (Gaussian Mixture Models)

La modellazione del colore consiste nel creare una tavola probabilistica dei colori caratteristici della pelle e della lesione. GrabCut utilizza due modelli di Gaussian Mixture Model (GMM) <sup>5</sup>:

- Il modello dello sfondo (**bgdModel**): impara la distribuzione dei toni cromatici RGB della cute sana presenti all'esterno del rettangolo.
- Il modello della *ROI* (**fgdModel**): impara la distribuzione dei toni cromatici scuri presenti all'interno del rettangolo.

I due modelli vengono allocati tramite due vettori NumPy di 65 elementi a 64 bit:

```
bgdModel = np.zeros((1, 65), np.float64)
fgdModel = np.zeros((1, 65), np.float64)
gc_mask = np.zeros((H, W), np.uint8)
```

Questi 65 valori servono a memorizzare le medie, le matrici di covarianza ed i pesi delle 5 componenti gaussiane che compongono la tavola cromatica di ciascuna delle due classi.

---


<sup>5</sup>Un modello di *Gaussian Mixture Model* è una funzione di densità probabilistica rappresentata come somma pesata di più distribuzioni gaussiane. Nel contesto dell'elaborazione delle immagini, permette di modellare la varietà di sfumature cromatiche presenti nella pelle o nella lesione suddividendole in sotto-insiemi di colore nello spazio RGB.

### 3. Costruzione del grafo ed iterazione Min-Cut

Una volta modellate le tavole cromatiche, GrabCut costruisce una rete sotto forma di grafo orientato  $G = (V, E)$ :

- **Nodi del Grafo ( $V$ ):** ciascun pixel dell'immagine costituisce un nodo del grafo. Inoltre vengono aggiunti due nodi esterni, detti *Terminali*: la **Source** ( $S$ ) rappresenta la classe di interesse (lesione) mentre il **Sink** ( $T$ ) rappresenta lo sfondo. Durante il taglio minimo del grafo, ogni pixel rimarrà connesso a uno solo dei due terminali, determinandone così la classe di appartenenza.
- **Neighbor links:** collegano tra loro i pixel adiacenti nella griglia spaziale. Il peso di ciascun arco è inversamente proporzionale al gradiente di contrasto tra i due pixel: quando due pixel vicini presentano una marcata variazione cromatica (in corrispondenza del bordo della lesione), la resistenza dell'arco è minima.
- **Terminal links:** collegano ciascun pixel ai due terminali  $S$  e  $T$ . Il peso di ciascun arco quantifica la probabilità calcolata dai modelli GMM, spiegando quanto il colore del pixel sia compatibile con la lesione o con la cute.

L'algoritmo individua la linea di separazione ottimale che recide gli archi del grafo a costo complessivo minimo. La linea di taglio attraversa preferenzialmente gli archi di vicinato a resistenza minima, coincidenti con il perimetro esterno del neo, separando la rete in due regioni disgiunte: i nodi che rimangono connessi alla *Source* formano la maschera binaria della lesione (valore 255), mentre i nodi connessi al *Sink* costituiscono lo sfondo cutaneo (valore 0).



**Figura 2.4** Architettura del grafo orientato  $S$ - $T$  ed ottimizzazione del taglio minimo nell'algoritmo GrabCut (Immagine riadattata da *Scaler Topics* [5]).

L'elaborazione si articola in una procedura di ottimizzazione iterativa. Ad ogni passaggio, l'algoritmo applica il teorema del *Min-Cut*, individuando e recidendo gli archi del grafo che separano la *Source* dal *Sink* con il minimo costo energetico complessivo. La conseguente ripartizione dei pixel tra lesione e cute sana consente di addestrare nuovamente le miscele Gaussiane (`bgdModel` e `fgdModel`), permettendo

alla linea di taglio di rimodellarsi con maggior accuratezza attorno al perimetro reale della lesione fino alla convergenza sul contorno finale. Nel codice implementato, l'intero processo iterativo è gestito dalla funzione `cv2.grabCut` [15], eseguita su un ciclo di 5 iterazioni:

**Listing 2.1** Processo di ottimizzazione iterativa di GrabCut ed estrazione della maschera binaria.

```
# 1. Esecuzione dell'ottimizzazione iterativa per 5 passaggi consecutivi
cv2.grabCut(img, gc_mask, rect, bgdModel, fgdModel, num_iter
            =5, mode=cv2.GC_INIT_WITH_RECT)
# 2. Assegnazione del valore 255 ai pixel identificati come lesione (GC_FGD o GC_PR_FGD)
mask_binary = np.where((gc_mask == cv2.GC_FGD) | (gc_mask ==
            cv2.GC_PR_FGD), 255, 0).astype(np.uint8)
```

### 2.2.3 Valutazione delle prestazioni di GrabCut

Al fine di valutare quantitativamente l'accuratezza delle maschere generate dall'algoritmo GrabCut rispetto al *Ground Truth* fornito da ISIC 2017, è stato calcolato il *Dice Similarity Coefficient* (DSC) su ciascuna immagine elaborata. L'algoritmo raggiunge un Dice Score medio pari a 78,5% dimostrando una capacità complessiva buona nell'isolare l'area lesionale.

















## 2.3 Analisi qualitativa e differenze principali tra i due approcci

Dall'analisi qualitativa delle immagini emerge che, nonostante GrabCut garantisca ottime prestazioni sulla maggior parte delle lesioni, mostra importanti limitazioni in presenza di specifici artefatti. Al contrario, l'architettura di Deep Learning *SkinMamba* dimostra una notevole robustezza nei confronti di tali artefatti, riuscendo a superare i limiti degli approcci basati unicamente sul contrasto locale. Nello specifico, il confronto si focalizza su due casi:

1. **Presenza di peli evidenti:** in presenza di peli evidenti sovrapposti alla lesione, GrabCut tende ad interpretare tali formazioni come barriere. Di conseguenza, il sistema può scambiare tali artefatti per il confine terminale della lesione oppure generare contorni ampiamente irregolari e seghettati. Un'ottimizzazione per questa fase della pipeline potrebbe consistere nell'introdurre un algoritmo di rimozione preventiva dei peli, come *DullRazor* [16], prima di avviare il processo di segmentazione. Al contrario, *SkinMamba* non si limita ad analizzare la discontinuità cromatica punto a punto, ma elabora rappresentazioni semantiche ad alto livello. Il modello è in grado di comprendere il contesto globale della lesione, riconoscendo i peli come elementi estranei sovrapposti.
2. **Vignettatura circolare:** molte acquisizioni dermoscopiche presentano un'ampia cornice circolare nera dovuta alla struttura del dermatoscopio. Quando il rettangolo di inizializzazione di GrabCut interseca tale cornice (*bounding box*)

interseca la cornice circolare, il modello GMM dello sfondo viene contaminato dai pixel neri. L’algoritmo finisce così per scambiare il bordo circolare del dermatoscopio per il margine esterno della lesione tumorale, segmentando l’intera cornice scura anziché il neo. *SkinMamba*, non richiede una *bounding box* ma processa l’intera immagine tramite mappe di attenzione e campi ricettivi multi-scala (modulo SMFFL). Ciò le consente di distinguere nettamente il cono d’ombra circolare del dermatoscopio dalla reale massa tumorale, focalizzando la segmentazione unicamente sulla lesione centrale.

Questi casi critici comportano un drastico crollo del *Dice Score* e confermano la necessità, nelle successive fasi di estrazione delle feature geometriche e classificazione, di fare affidamento sulle maschere validate *Ground Truth*, così da non propagare tali errori morfologici ai modelli predittivi.

| (1) Immagine RGB                                                                    | (2) GrabCut                                                                         | (3) SkinMamba                                                                        | (4) Ground Truth (ISIC)                                                               |
|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
|   |   |   |   |
|  |  |  |  |
|  |  |  |  |
|  |  |  |  |

**Figura 2.5** Confronto visivo tra i metodi di segmentazione su 4 campioni rappresentativi del dataset: (1) Immagine dermoscopia originale RGB, (2) Maschera binaria generata da *GrabCut*, (3) Maschera generata dalla rete neurale profonda *SkinMamba*, (4) Maschera di riferimento *Ground Truth* ISIC.

## Capitolo 3

# Analisi geometrica e statistica delle lesioni cutanee

In questo capitolo viene descritta la metodologia utilizzata per l'analisi geometrica delle lesioni cutanee presenti nel dataset ISIC 2017.

L'obiettivo del lavoro è stato quello di trasformare le informazioni geometriche contenute nelle maschere di segmentazione delle lesioni in caratteristiche numeriche in grado di descriverne la morfologia.

La pipeline sviluppata è composta dalle seguenti fasi:

- analisi del dataset;
- utilizzo delle maschere di segmentazione Ground Truth;
- estrazione del contorno della lesione;
- calcolo degli indici geometrici e di irregolarità;
- valutazione statistica delle caratteristiche estratte.

### 3.1 Dataset ISIC 2017 e preparazione dei dati

La prima fase del lavoro si è concentrata sull'analisi del dataset clinico ufficiale **ISIC Skin Lesion 2017** [8].

Il dataset è composto da 2000 immagini dermoscopiche accompagnate dalle relative informazioni diagnostiche e dalle corrispondenti maschere di segmentazione.

Le categorie diagnostiche presenti sono:

| Categoria Diagnostica          | Conteggio Campioni |
|--------------------------------|--------------------|
| Nevo (Benigno)                 | 1372               |
| Melanoma (Maligno)             | 374                |
| Cheratosi Seborroica (Benigno) | 254                |
| <b>Totale Immagini</b>         | <b>2000</b>        |


**Tabella 3.1** Suddivisione del dataset ISIC 2017 per categoria specifica.

Ai fini dell'analisi statistica le categorie sono state successivamente raggruppate in due classi:

| Classe   | Numero immagini |
|----------|-----------------|
| Benigno  | 1626            |
| Melanoma | 374             |

**Tabella 3.2** Suddivisione binaria utilizzata nell'analisi statistica.

Per supportare visivamente lo studio statistico descritto, i dati sono stati rappresentati anche graficamente:



**Figura 3.1** A sinistra troviamo il grafico per categoria specifica. A destra troviamo la divisione tra benigno (Nevi + Cheratosi) e maligno.

## 3.2 Estrazione delle caratteristiche geometriche

A partire dalla maschera binaria vengono estratti: il contorno della lesione, l'area, il perimetro e i diametri principali tramite fitting ellittico.

### 3.2.1 Metrica di discostamento ellittico

Per l'analisi dettagliata delle irregolarità del bordo è stata studiata una metrica personalizzata denominata  $m$ . Essa si basa sull'ipotesi che una lesione benigna della pelle tenda ad approssimare una geometria ellittica regolare; quindi è fondamentale misurare quanto i bordi del neo si discostano dalla forma di un'ellisse perfetta.

Il calcolo di  $m$  è stato implementato in un ambiente Python utilizzando la libreria OpenCV (cv2) [15], secondo i seguenti passaggi:

1. **Estrazione del contorno principale:** l'identificazione del perimetro della lesione è stata eseguita tramite la funzione `cv2.findContours` impostando `cv2.RETR_EXTERNAL` per estrarre solamente il bordo esterno del neo e `cv2.CHAIN_APPROX_NONE` per la memorizzazione della posizione di tutti i pixel.

Per garantire la robustezza rispetto ad eventuale rumore di fondo, è stato selezionato esclusivamente il contorno con area massima, calcolata tramite la funzione `cv2.contourArea`.

2. **Ellipse fitting:** Sul contorno estratto è stato eseguito il fitting algoritmico di un'ellisse ottimale ai minimi quadrati mediante la funzione `cv2.fitEllipse`. Questa operazione ha permesso di ricavare i parametri geometrici fondamentali della lesione: le coordinate del centro  $(x_c, y_c)$ , le lunghezze dei semiassi maggiore ( $a = GD/2$ ) e minore ( $b = SD/2$ ), e l'angolo di inclinazione  $\theta$  espresso rispetto all'asse verticale.
3. **Allineamento spaziale:** Poiché le lesioni presentano un'orientazione arbitraria nel piano, è necessario eseguire una trasformazione di coordinate prima di poter confrontare i bordi. Senza questo allineamento il calcolo della distanza confronterebbe i punti del contorno reale con un'ellisse ideale disallineata, introducendo un errore non relativo al bordo effettivo. I punti del contorno reale sono stati quindi traslati rispetto al centro e ruotati applicando una matrice di rotazione operante sull'angolo  $-\theta$ :

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} \cos(-\theta) & -\sin(-\theta) \\ \sin(-\theta) & \cos(-\theta) \end{bmatrix} \begin{bmatrix} x_i - x_c \\ y_i - y_c \end{bmatrix}$$

4. **Coordinate polari ed errore relativo:** Una volta allineato il sistema di riferimento, le coordinate cartesiane appena trasformate  $(x'_i, y'_i)$  sono state convertite in coordinate polari per mappare il raggio reale  $r_i = \sqrt{x'^2_i + y'^2_i}$  e l'angolo  $\alpha_i = \arctan 2(y'_i, x'_i)$ . Il raggio teorico dell'ellisse fittata ( $r_{ell}$ ) per ciascun angolo  $\alpha_i$  è stato calcolato sfruttando l'equazione polare canonica:

$$r_{ell}(\alpha_i) = \frac{a \cdot b}{\sqrt{(a \cdot \cos \alpha_i)^2 + (b \cdot \sin \alpha_i)^2}}$$

5. **Formulazione della metrica m:** L'errore morfologico è stato determinato calcolando la differenza in modulo tra il raggio reale e il raggio teorico, normalizzata rispetto al raggio dell'ellisse stessa. La metrica globale  $m$  è espressa come la radice dell'errore quadratico medio relativo (RMSRE) calcolato sugli  $N$  punti validi del contorno:

$$m = \sqrt{\frac{1}{N} \sum_{i=1}^N \left( \frac{r_i - r_{ell}(\alpha_i)}{r_{ell}(\alpha_i)} \right)^2}$$

Un valore di  $m \rightarrow 0$  indica una lesione geometricamente perfetta, coincidente con il modello ellittico liscio, mentre valori elevati indicano una marcata presenza di asimmetrie morfologiche sul bordo della lesione binarizzata. Abbiamo quindi ottenuto i seguenti parametri della lesione cutanea: Area ( $A$ ), Perimetro ( $P$ ) e i diametri approssimati (Diametro Minore  $SD$  e Diametro Maggiore  $GD$ ).

### 3.2.2 Indici di Irregolarità del bordo

Al fine di tradurre in entità numeriche i bordi irregolati, sono stati implementati quattro indici. Gli indici morfologici implementati in questo lavoro si basano sulla metodologia validata da Garnavi et al. [11].:

- **Indice di Irregolarità A ( $I_a$ ):** Valuta il rapporto diretto tra il perimetro e l'area della lesione.

$$I_a = \frac{P}{A}$$

Una lesione con bordi molto frastagliati presenterà un perimetro significativamente maggiore in proporzione alla sua area, otterremo quindi un valore molto elevato.

- **Indice di Irregolarità B ( $I_b$ ):** Rapporto tra la lunghezza del contorno e l'estensione massima lineare della lesione.

$$I_b = \frac{P}{GD}$$

Una lesione con bordi molto frastagliati presenterà un valore molto alto.

- **Indice di Irregolarità C ( $I_c$ ):** Metrica combinata che amplifica matematicamente l'irregolarità nei casi in cui la lesione presenti contemporaneamente uno stiramento spaziale e un bordo frastagliato.

$$I_c = P \cdot \left( \frac{1}{SD} - \frac{1}{GD} \right)$$

- **Indice di Irregolarità D ( $I_d$ ):** Differenza scalare assoluta (in pixel) tra i due assi diametrali.

$$I_d = GD - SD$$

### 3.2.3 Quantificazione dell'asimmetria

Infine abbiamo valutato l'asimmetria della lesione, poiché le lesioni maligne tendono a mostrare una crescita non uniforme rispetto agli assi di simmetria [17]. Per rendere tale metrica totalmente invariante rispetto alla rototraslazione della lesione all'interno del piano dell'immagine, è stata implementata una pipeline computazionale basata sulla teoria dei momenti geometrici e sulla rotocompensazione assi-simmetrica.

#### Teoria dei Momenti e orientazione dell'asse principale

Data una maschera binarizzata definita da una funzione di intensità discreta  $I(x, y) \in \{0, 255\}$ , i momenti spaziali di ordine  $(p + q)$  sono definiti come:

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y)$$

Il calcolo dei momenti di ordine zero e uno permette di determinare le coordinate del centro geometrico  $(\bar{x}, \bar{y})$  della lesione:

$$\bar{x} = \frac{m_{10}}{m_{00}}, \quad \bar{y} = \frac{m_{01}}{m_{00}}$$

Al fine di garantire l'invarianza per traslazione, vengono calcolati i momenti centrali  $\mu_{pq}$ , i quali traslano l'origine del sistema di riferimento direttamente nel centro della massa:

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y)$$

I momenti centrali del secondo ordine  $(\mu_{20}, \mu_{02}, \mu_{11})$  descrivono la distribuzione spaziale dei pixel attorno al baricentro, configurando una matrice di covarianza spaziale. L'orientazione dell'asse principale d'inerzia (l'asse di minima resistenza rotazionale della figura) coincide con l'autovettore associato all'autovalore massimo di tale matrice. L'angolo d'inclinazione  $\theta$  rispetto all'asse delle ascisse viene ricavato analiticamente risolvendo la seguente equazione:

$$\tan(2\theta) = \frac{2\mu_{11}}{\mu_{20} - \mu_{02}}$$

Da cui si estrae l'angolo di rotazione ottimale:

$$\theta = \frac{1}{2} \arctan 2(2\mu_{11}, \mu_{20} - \mu_{02})$$

Una volta stimato l'angolo  $\theta$ , l'intero insieme di punti della maschera viene sottoposto ad una trasformazione affine di rotazione rigida utilizzando come fulcro il centro  $(\bar{x}, \bar{y})$ . Questo processo mappa la lesione in un nuovo sistema di riferimento in cui l'asse principale d'inerzia risulta perfettamente allineato con l'asse cartesiano orizzontale. Questo passaggio è fondamentale poiché senza l'allineamento preventivo, l'operazione di ribaltamento confronterebbe regioni spaziali errate.

Definita  $M_{rot}$  la maschera ruotata e allineata, viene generata una seconda maschera specchiata  $M_{flip}$  eseguendo una riflessione geometrica attorno all'asse ortogonale passante per il centro. La quantificazione matematica dell'asimmetria viene infine effettuata applicando l'operatore logico bivalente XOR (OR esclusivo) tra la maschera allineata e la sua rispettiva specchiata:

$$M_{\Delta}(x, y) = M_{rot}(x, y) \oplus M_{flip}(x, y)$$

L'operatore XOR isola esclusivamente le regioni non sovrapponibili, ovvero i pixel che non trovano una corrispondenza simmetrica nella metà opposta della lesione. L'Indice di Asimmetria percentuale viene normalizzato rispetto all'area totale della lesione ( $A_{tot} = m_{00}$ ) secondo la formulazione:

$$\text{Asymmetry Index (\%)} = \left( \frac{\sum M_{\Delta}(x, y)/2}{A_{tot}} \right) \times 100$$

Il fattore di normalizzazione diviso per 2 è introdotto poiché la discrepanza geometrica viene conteggiata simmetricamente due volte dall'operatore logico su entrambi i lati dell'asse di riflessione.

### 3.3 Risultati dell'Estrazione


Nella Tabella 3.3 si riporta la sintesi statistica globale delle feature geometriche estratte sull'intero corpus di immagini ISIC 2017.

| Feature Geometrica              | Media  | Minimo | Massimo |
|---------------------------------|--------|--------|---------|
| Discostamento Ellittico ( $m$ ) | 0.067  | 0.011  | 0.375   |
| Irregolarità A ( $I_a$ )        | 0.009  | 0.0008 | 0.048   |
| Irregolarità B ( $I_b$ )        | 3.554  | 2.126  | 13.446  |
| Irregolarità C ( $I_c$ )        | 1.261  | 0.022  | 13.164  |
| Irregolarità D ( $I_d$ )        | 279.07 | 2.806  | 3013.05 |
| Indice di Asimmetria (%)        | 8.20%  | 1.43%  | 39.84%  |

**Tabella 3.3** Riassunto statistico delle feature morfologiche.

Guardando i numeri nella tabella 3, si nota una grande differenza tra le lesioni. Per esempio l'ampia variabilità di percentuale nell'indice di asimmetria: si passa da un minimo dell'1.43%, che corrisponde a forme molto compatte e regolari, fino a quasi il 40% per le lesioni più complesse. Questa differenza di percentuale così ampia è necessaria per distinguere un neo sano da uno malato. Quindi, l'irregolarità clinica, visibile ad occhio nudo, è stata tradotta in un linguaggio numerico che può essere letto da un modello e usato per imparare a distinguere le due classi.

Al fine di convalidare le feature geometriche, le metriche sono state incrociate con i dati diagnostici del Ground Truth. Attraverso l'uso di istogrammi a frequenza sovrapposta, è stato possibile visualizzare la differente distribuzione numerica tra le lesioni maligne (Melanoma) e benigne (Nevi e Cheratosi).



**Figura 3.2** Istogrammi di distribuzione delle feature condizionati alla classe diagnostica.

### 3.4 Analisi statistica delle feature geometriche

Dopo l'estrazione delle caratteristiche geometriche dalle maschere di segmentazione, è stata effettuata un'analisi statistica con l'obiettivo di verificare se gli indici morfologici

riescano a discriminare significativamente tra lesioni maligne e nevi benigni.

### 3.4.1 Test statistico di Mann–Whitney

Per confrontare le distribuzioni degli indici geometrici tra i due gruppi è stato utilizzato il test non parametrico di Mann–Whitney.

La scelta di un test non parametrico è dovuta al fatto che le feature estratte dalle lesioni non sono necessariamente distribuite secondo una distribuzione normale. Questo test permette quindi di confrontare due popolazioni indipendentemente dalla loro distribuzione.

Per ogni indice è stata definita la seguente ipotesi nulla:

$$H_0 : F_{Benigno}(x) = F_{Melanoma}(x)$$

ovvero le distribuzioni dei valori dell'indice sono uguali nei due gruppi.

L'ipotesi alternativa è:

$$H_1 : F_{Benigno}(x) \neq F_{Melanoma}(x)$$

ovvero esiste una differenza statisticamente significativa tra la distribuzione dell'indice nei due gruppi.

Il test confronta tutte le possibili coppie di osservazioni appartenenti ai due gruppi:

$$U = \sum_{i=1}^{n_1} \sum_{j=1}^{n_2} S(x_i > y_j)$$

dove:

- $n_1$  e  $n_2$  rappresentano il numero di campioni dei due gruppi;
- $x_i$  è un valore appartenente al primo gruppo;
- $y_j$  è un valore appartenente al secondo gruppo;
- $S$  è la funzione indicatrice, che assume valore 1 quando  $x_i > y_j$ , 1/2 quando  $x_i = y_j$  e 0  $x_i < y_j$ .

In pratica, la statistica  $U$  misura quante volte un elemento di un gruppo presenta un valore maggiore rispetto ad un elemento dell'altro gruppo.

### 3.4.2 Interpretazione del p-value

La potenza del test viene valutata mediante il calcolo p-value. Esso indica la probabilità di osservare una differenza pari o superiore a quella campionaria, sotto l'assunzione che l'ipotesi nulla  $H_0$  sia corretta.

È stata utilizzata una soglia di significatività:

$$\alpha = 0.05$$

La decisione statistica segue la seguente regola:

$$p < 0.05 \Rightarrow \text{rifiuto } H_0$$

$$p \geq 0.05 \Rightarrow \text{non è possibile rifiutare } H_0$$

Un valore di p-value molto basso indica quindi che la differenza osservata tra benigni e melanomi difficilmente è dovuta al caso. Un valore di p-value molto basso indica quindi che la differenza osservata tra le lesioni è statisticamente significativa, rendendo questa caratteristica rilevante ai fini della classificazione.

### 3.4.3 Risultati del test statistico

Il test è stato applicato singolarmente a ciascuna feature geometrica estratta. I risultati ottenuti sono riportati nella Tabella 3.4.

| Indice          | Statistica U | p-value                |
|-----------------|--------------|------------------------|
| $m$             | 210074.0     | $1.02 \times 10^{-20}$ |
| $I_a$           | 372245.0     | $1.28 \times 10^{-11}$ |
| $I_b$           | 299119.0     | 0.6236                 |
| $I_c$           | 287043.0     | 0.0910                 |
| $I_d$           | 288121.0     | 0.1134                 |
| Asymmetry Index | 237851.0     | $4.86 \times 10^{-11}$ |

**Tabella 3.4** Risultati del test statistico Mann–Whitney per ogni indice geometrico.

Dai risultati emerge che gli indici:  $m$ ,  $I_a$ , *Asymmetry\_index* presentano un p-value inferiore alla soglia di significatività, pertanto l'ipotesi nulla viene rifiutata. Questo indica che tali caratteristiche hanno distribuzioni significative differenti tra lesioni benigne e melanomi. Al contrario, gli indici:  $I_b$ ,  $I_c$ ,  $I_d$  non mostrano una differenza significativa poiché il p-value risulta superiore a 0.05.

### 3.4.4 Rappresentazione tramite diagrammi scatola e baffi

Per supportare visivamente il risultato del test statistico sono stati utilizzati i diagrammi scatola e baffi.

Questo diagramma permette di confrontare la distribuzione degli indici nei due gruppi attraverso:

- la **mediana**, rappresentata dalla linea centrale della scatola;
- il **primo** e **terzo quartile**, che definiscono l'altezza della scatola;
- i **baffi**, che indicano la variabilità dei dati;
- eventuali valori anomali (*outlier*).

Una maggiore separazione tra le distribuzioni dei due gruppi suggerisce una maggiore capacità discriminante dell'indice considerato.



**Figura 3.3** Diagrammi scatola e baffi degli indici geometrici confrontati tra lesioni benigne e melanomi.

Possiamo quindi confermare che le feature più discriminanti sono l'*asymmetry\_index*,  $m$  e  $I_a$ . Nel caso dei primi due, notiamo che i box dei melanomi sono spostati verso l'alto rispetto a quelli dei benigni. Anche le mediane sono distanti. Questo ci indica che queste feature differenziano molto bene le classi.

## Capitolo 4

# Classificazione

In questo capitolo verrà descritta l'implementazione della di classificazione delle lesioni cutanee, strutturata come un problema di classificazione binaria volto a distinguere tra lesioni **benigne** (classe 0) e **melanomi** (classe 1).

### 4.1 Caratteristiche del dataset e pre-elaborazione

Il dataset analizzato presenta un marcato sbilanciamento delle classi, riflettendo la reale incidenza clinica delle patologie cutanee:

- **Lesioni Benigne:** 1.626 campioni ( $\approx 81,3\%$ )
- **Melanomi:** 374 campioni ( $\approx 18,7\%$ )

La classificazione è stata eseguita utilizzando le tre metriche geometriche precedentemente estratte:  $m$ , l'indice di asimmetria radiale ( $I_a$ ) e l'indice di asimmetria globale (*asymmetry index*).

Queste metriche presentano ordini di grandezza diversi tra loro. Molti algoritmi di classificazione, che lavorano calcolando distanze e pesi, sono sensibili alla scala dei dati e l'addestramento su dati grezzi condurrebbe ad un apprendimento sbilanciato. L'algoritmo, in questo caso, tenderebbe ad attribuire più peso a metriche con valori più elevati. Per evitare quest'errore, è stata applicata la standardizzazione tramite *StandardScaler* [12], trasformando ciascuna variabile nel rispettivo  $Z$ -score:

$$z = \frac{x - \mu}{\sigma} \quad (4.1)$$

dove  $x$  rappresenta il valore originale,  $\mu$  la media della feature calcolata sul dataset di addestramento e  $\sigma$  la relativa deviazione standard. In questo modo tutte le feature vengono compresse sulla stessa scala.

### 4.2 Addestramento e validazione

Per contrastare lo sbilanciamento del dataset ed evitare che i modelli penalizzino la classe in minoranza, è stata introdotta una funzione di costo pesata (*Class Weight*). In ambito dermatologico, il **falso negativo** (un melanoma erroneamente

diagnosticato come benigno) rappresenta l'errore clinico più critico. Di conseguenza, è stata assegnata una funzione dei costi asimmetrica:

$$\text{Class Weight} = \{0 : 1, 1 : 4\} \quad (4.2)$$

Tale configurazione attribuisce un costo dell'errore quadruplo alla misclassificazione di un melanoma rispetto a quella di una lesione benigna.

La valutazione delle prestazioni è stata condotta mediante una *5-Fold Cross-Validation Stratificata*, garantendo che la proporzione originale tra la classe benigna e maligna fosse conservata all'interno di ogni *fold*.

### 4.3 Algoritmi a confronto

Al fine di condurre un'analisi comparativa, sono stati implementati ed esaminati cinque diversi algoritmi di machine learning. La scelta degli algoritmi è stata inoltre motivata dalla loro applicazione in precedenti studi sulla classificazione di lesioni cutanee mediante immagini dermoscopiche, tra cui il lavoro di Shetty et al. [6] e Kassem et al. [7].

1. **Regressione Logistica:** un modello lineare probabilistico utilizzato come baseline di riferimento. È stato scelto per la sua semplicità, la notevole interpretabilità e il ridotto costo computazionale.
2. **Decision Tree:** questo algoritmo genera regole decisionali con una struttura logica "*se-allora*". Risulta molto utile in ambito medico poiché è il modello che più rispecchia il processo logico diagnostico a cascata.
3. **Random Forest:** un metodo *ensemble* (apprendimento d'insieme) basato su alberi decisionali multipli. È noto in letteratura per la sua robustezza all'overfitting e la capacità di gestire relazioni non lineari complesse, tipiche delle immagini cliniche.
4. **Bagging Classifier:** un algoritmo che accorpa le predizioni di più predittori addestrati su sottoinsiemi di campioni casuali; è stato incluso per la sua capacità di ridurre la varianza del modello, garantendo predizioni più stabili su dataset sensibili al rumore.
5. **Gradient Boosting Classifier:** un algoritmo *ensemble* sequenziale, dove ogni nuovo modello corregge gli errori dei precedenti. Questo tipo di apprendimento fornisce un'alta capacità per catturare le differenze più sottili che diversificano un melanoma da un nevo.

Le metriche utilizzate per valutare ciascun algoritmo sono:

- **Accuracy:**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.3)$$

Misura la percentuale complessiva di predizioni corrette (sia maligne che benigne) sul totale dei casi valutati.

- **Precision:**

$$Precision = \frac{TP}{TP + FP} \quad (4.4)$$

Misura la proporzione di lesioni classificate come melanomi che sono effettivamente maligne. Una bassa precisione implica un elevato numero di falsi positivi.

- **Recall:**

$$Recall = \frac{TP}{TP + FN} \quad (4.5)$$

Misura la capacità del modello di individuare correttamente tutti i melanomi reali. In un sistema di screening questa è la metrica prioritaria: un falso negativo comporta una mancata o ritardata diagnosi, con conseguenze importanti per il paziente.

- **F1-Score:**

$$F1-Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (4.6)$$

Rappresenta la media armonica tra Precision e Recall. È una metrica cruciale in presenza di dataset fortemente sbilanciati, come in questo caso, poiché offre un singolo valore che penalizza i modelli che favoriscono eccessivamente una classe rispetto all'altra.

- **ROC-AUC (Area Under the ROC Curve):**

$$AUC = \int_0^1 t_{pr}(f_{pr}) \delta f_{pr} \quad (4.7)$$

La curva ROC (*Receiver Operating Characteristic*) rappresenta graficamente il compromesso tra il tasso di veri positivi ( $t_{PR}$ , ovvero la Recall) e il tasso di falsi positivi ( $f_{pr}$ ) al variare della soglia decisionale. L'AUC ne calcola l'integrale: un valore pari a 0.5 indica una classificazione poco precisa, mentre 1.0 rappresenta un modello perfetto. In ambito medico, è considerata una delle metriche più robuste poiché valuta la capacità intrinseca dell'algoritmo di discriminare tra lesioni maligne e benigne, indipendentemente dallo sbilanciamento delle classi e dalla soglia scelta.

- **Matrice di Confusione:** Non è un valore scalare, ma una tabella  $2 \times 2$  che categorizza le predizioni nei quattro esiti possibili: Veri Positivi ( $TP$ ), Veri Negativi ( $TN$ ), Falsi Positivi ( $FP$ ) e Falsi Negativi ( $FN$ ).

$$C = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix} \quad (4.8)$$

Permette al medico di quantificare il valore esatto degli errori, distinguendo chiaramente quante lesioni benigne porterebbero a ulteriori controlli superflui ( $FP$ ) e, soprattutto, quanti melanomi verrebbero ignorati dal sistema ( $FN$ ).

## Risultati

**Tabella 4.1** Risultati di classificazione dettagliati per classe con metriche globali (5-Fold Cross-Validation).

| Modello             | Classe   | Precision     | Recall        | F1-Score     | Accuracy      | ROC-AUC       |
|---------------------|----------|---------------|---------------|--------------|---------------|---------------|
| Decision Tree       | Benigno  | 89.27%        | 57.31%        | 0.696        | 59.70%        | 0.6663        |
|                     | Melanoma | 27.70%        | <b>70.03%</b> | 0.395        |               |               |
| Logistic Regression | Benigno  | 87.47%        | 72.20%        | <b>0.791</b> | 69.00%        | <b>0.7088</b> |
|                     | Melanoma | <b>31.43%</b> | 55.09%        | <b>0.400</b> |               |               |
| Gradient Boosting   | Benigno  | 86.94%        | 70.54%        | 0.778        | 67.40%        | 0.6802        |
|                     | Melanoma | 29.56%        | 53.76%        | 0.381        |               |               |
| Bagging Classifier  | Benigno  | 83.91%        | 81.86%        | 0.829        | 72.50%        | 0.6318        |
|                     | Melanoma | 29.03%        | 31.83%        | 0.303        |               |               |
| Random Forest       | Benigno  | 83.89%        | 84.56%        | 0.842        | <b>74.25%</b> | 0.6444        |
|                     | Melanoma | 30.49%        | 29.41%        | 0.299        |               |               |

Per analizzare il comportamento globale di ciascun modello sull'intero dataset, oltre alla valutazione su singola classe, le metriche *Precision*, *Recall* e *F1-score* sono state quantificate in due modi diversi:

- **Media ponderata:** calcola il valore complessivo pesando la prestazione ottenuta su ogni classe in base alla sua frequenza nel dataset. I pesi per ciascuna classe sono stati calcolati come:

$$w_0 = \frac{N_0}{N} = \frac{1626}{2000} = 0,813 \quad (4.9)$$

$$w_1 = \frac{N_1}{N} = \frac{374}{2000} = 0,187 \quad (4.10)$$

dove  $N$  rappresenta il numero totale di campioni ( $N = 2.000$ ),  $N_i$  è il numero di campioni appartenenti alla classe  $i$  e  $\mathcal{M}_i$  indica la metrica calcolata per la classe  $i$ , con:

$$i = \begin{cases} 0, & \text{se la lesione è benigna} \\ 1, & \text{se la lesione è un melanoma} \end{cases} \quad (4.11)$$

La metrica finale pesata  $\mathcal{M}_{\text{Weighted}}$  si ottiene applicando i pesi:

$$\mathcal{M}_{\text{Weighted}} = w_0 \cdot \mathcal{M}_0 + w_1 \cdot \mathcal{M}_1 = 0,813 \cdot \mathcal{M}_0 + 0,187 \cdot \mathcal{M}_1 \quad (4.12)$$

- **Media Macro:** calcola la media aritmetica semplice tra le prestazioni delle due classi, assegnando pari peso teorico a ciascuna categoria indipendentemente dallo sbilanciamento campionario:

$$\mathcal{M}_{\text{Macro}} = \frac{\mathcal{M}_0 + \mathcal{M}_1}{2} \quad (4.13)$$

**Tabella 4.2** Risultati di classificazione aggregati a livello globale (Weighted vs Macro) con 5-Fold Cross-Validation.

| Modello             | Tipo media | Precision     | Recall        | F1-Score      | Accuracy      | ROC-AUC       |
|---------------------|------------|---------------|---------------|---------------|---------------|---------------|
| Decision Tree       | Ponderata  | <b>77.76%</b> | 59.69%        | 0.6395        | 59.70%        | 0.6663        |
|                     | Macro      | 58.48%        | 63.67%        | 0.5455        |               |               |
| Logistic Regression | Ponderata  | 76.99%        | 69.00%        | 0.7177        | 69.00%        | <b>0.7088</b> |
|                     | Macro      | <b>59.45%</b> | 63.65%        | 0.5953        |               |               |
| Gradient Boosting   | Ponderata  | 76.21%        | 67.40%        | 0.7039        | 67.40%        | 0.6802        |
|                     | Macro      | 58.25%        | 62.15%        | 0.5794        |               |               |
| Bagging Classifier  | Ponderata  | 73.64%        | 72.50%        | 0.7303        | 72.50%        | 0.6318        |
|                     | Macro      | 56.47%        | 56.84%        | 0.5659        |               |               |
| Random Forest       | Ponderata  | 73.91%        | <b>74.25%</b> | <b>0.7407</b> | <b>74.25%</b> | 0.6444        |
|                     | Macro      | 57.19%        | 56.99%        | 0.5708        |               |               |


Dall'analisi delle medie delle metriche possiamo fare alcune considerazioni fondamentali relative allo sbilanciamento del dataset e alla complessità dei vari modelli. Notiamo inizialmente che le metriche ponderate hanno valori più elevati in quanto la classe delle lesioni benigne, con peso maggioritario, presenta di per sé una precisione molto alta. Diversamente, le metriche valutate con media semplice mostrano la reale difficoltà nel discernere i melanomi tramite il solo utilizzo di metriche geometriche. Il modello che garantisce risultati più solidi è la regressione logistica, il modello strutturalmente meno complesso. Tale risultato è da attribuire al fatto che il lavoro di classificazione si basa su sole tre variabili geometriche ( $m$ ,  $I_a$ , *Asymmetry index*). In questa circostanza, i modelli più complessi, come gli algoritmi ensemble, tendono a creare soglie di decisione eccessivamente strutturate rischiando l'overfitting. Inoltre, la funzione sigmoide trasforma la combinazione lineare delle feature in una probabilità continua  $p \in (0, 1)$ :

$$p = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.14)$$

L'utilizzo dei *Class Weight* nella funzione di loss (*Weighted Binary Cross-Entropy*) aggiorna i pesi dei gradienti durante l'ottimizzazione, traslando la soglia decisionale in modo continuo. A differenza degli algoritmi basati su alberi, che generano soglie di decisione rigide, la curvatura liscia della sigmoide permette di massimizzare la *Recall* sui melanomi mantenendo un'ottima *Precision* sulle lesioni benigne, garantendo così un'elevata capacità selettiva. La stabilità di questo bilanciamento viene inoltre confermata dal valore dell'area sotto la curva *ROC*.


In seguito vengono riportate le matrici di confusione di ciascun classificatore (4.1, 4.2, 4.3, 4.4 e 4.5). Osservando i grafici si nota che il *Decision Tree* ha il minimo tasso di falsi negativi dell'intera sperimentazione, ignorando solamente 112 melanomi. Con questo metodo si minimizza il rischio che una lesione maligna non venga sottoposta ad un controllo specialistico, generando però un numero elevato di falsi allarmi (falsi positivi). Inoltre constatiamo, nuovamente, come il modello più bilanciato sia la *regressione logistica* poiché individua la maggior parte dei melanomi e contemporaneamente abbate in modo significativo i falsi positivi, evitando così

controlli dermatologici superflui. Infine si nota che il *random forest* e *bagging classifier* mostrano un comportamento clinico particolarmente critico. Il classificatore random forest individua correttamente solo il  $\approx 30\%$  dei melanomi totali, similmente il bagging.




**Figura 4.1** Matrice di confusione ottenuta per il classificatore *Decision tree*.

**Figura 4.2** Matrice di confusione per il classificatore *Bagging*.



**Figura 4.3** Matrice di confusione per il classificatore *Gradient boosting*.

**Figura 4.4** Matrice di confusione per il classificatore *Regressione logistica*.



**Figura 4.5** Matrice di confusione per il classificatore *Random forest*.

## Capitolo 5

# Conclusione

Nel presente lavoro di tesi è stato progettato, implementato e validato un sistema computazionale per il supporto alla diagnosi dermatologica delle lesioni cutanee, focalizzato sulla classificazione binaria tra lesioni benigne e melanoma maligno, basato sulla traduzione matematica ed interpretabile dei criteri della regola clinica ABCD. La sperimentazione è stata condotta sulle 2000 immagini del dataset di riferimento **ISIC-2017** [8]. Nelle fasi iniziali dello studio sono stati condotti diversi esperimenti di segmentazione automatica per la generazione delle maschere binarie; tuttavia, data l'estrema variabilità dei contorni lesionali e la presenza di artefatti cutanei, tali tentativi non hanno raggiunto un livello di accuratezza sufficientemente robusto da poter sostituire le maschere ufficiali del dataset ISIC. Al fine di garantire la massima affidabilità e solidità nell'estrazione delle feature, l'analisi è stata quindi basata sulle maschere ufficiali (*Ground Truth*). A partire da tali maschere, le metriche geometriche e di forma sono state estratte mediante l'adattamento di un'ellisse equivalente basata sui momenti centrali del secondo ordine del contorno. Tale metodologia ha consentito di quantificare la deviazione radiale rispetto all'ellisse ideale ( $m$ ), l'indice di compattezza perimetro/area ( $I_a$ ), i rapporti dimensionali ( $I_b, I_c, I_d$ ) e l'indice di asimmetria percentuale. Successivamente è stata condotta un'analisi statistica, tramite il test di Mann-Whitney, e come riportato nella Tabella 3.4, il discostamento ellittico ( $m$ ), l'indice di compattezza ( $I_a$ ) e l'asimmetria hanno mostrato differenze altamente significative tra nevi e melanomi ( $p \ll 0.001$ ). Viceversa, gli indici dimensionali  $I_b, I_c$  e  $I_d$  non hanno evidenziato variazioni statisticamente rilevanti, risultando non idonei alla selezione. Infine, la classificazione è stata condotta in 5-Fold Stratified Cross-Validation con pesatura asimmetrica delle classi (*Class Weighting* 4 : 1). Dai risultati medi ottenuti, sintetizzati nella Tabella 4.2, emergono considerazioni cruciali per il contesto clinico: l'albero decisionale ha massimizzato la sensibilità clinica, raggiungendo una recall sul melanoma del 70.03%. In uno scenario di screening preliminare, tale modello risulta il più prudente, riducendo nettamente il tasso di falsi negativi. La regressione logistica ha mostrato la migliore capacità globale di separazione stocastica, registrando l'area sotto la curva ROC più elevata (ROC-AUC = 0.7088) e garantendo un trade-off ottimale tra accuratezza globale (69.00%) e sensibilità sul tumore maligno (55.09%). Mentre gli algoritmi ensemble (*Random Forest* e *Bagging*), pur conseguendo valori superiori di accuratezza complessiva ( $> 72\%$ ), hanno manifestato una tendenza a privilegiare la classe

maggioritaria benigna, rendendoli meno indicati rispetto ad altri modelli. Un aspetto rilevante del metodo proposto è la possibilità di ottenere una descrizione quantitativa della lesione a partire da caratteristiche geometriche direttamente interpretabili. A differenza di una classificazione basata esclusivamente sull'output di un modello, gli indici considerati permettono di collegare il risultato alle proprietà della lesione da cui esso deriva, come l'irregolarità del contorno e l'asimmetria. Questo rende l'analisi facilmente verificabile e consente di individuare quali caratteristiche contribuiscano maggiormente alla distinzione tra le diverse classi. A questo si aggiunge la semplicità di calcolo: l'estrazione delle misure e la risposta del modello richiedono pochi millisecondi. Questo rende il sistema facilmente utilizzabile anche su dispositivi comuni, senza dover dipendere da server potenti. Infine, l'uso di una validazione incrociata a 5 fold ha evitato errori metodologici frequenti, come il data leakage<sup>1</sup>, garantendo che i risultati ottenuti siano affidabili e rispecchino il reale comportamento del modello su nuove immagini. Emergono tuttavia alcuni limiti metodologici intrinseci. In primo luogo, l'analisi si basa unicamente su parametri di forma e geometria, escludendo informazioni cliniche fondamentali come la variazione cromatica e i pattern di texture, quali reticoli pigmentari atipici, strie o globuli [8]. Inoltre, un ulteriore limite riguarda la segmentazione della lesione: poiché le metriche geometriche vengono calcolate direttamente a partire dal contorno della maschera, eventuali errori di segmentazione possono influenzare i valori degli indici e, di conseguenza, la classificazione. Nel presente lavoro questo problema è stato limitato mediante l'utilizzo delle maschere ufficiali fornite dal dataset ISIC 2017; tuttavia, in un'applicazione completamente automatica, sarebbe necessario disporre di un metodo di segmentazione sufficientemente accurato e robusto.

## 5.1 Sviluppi futuri

I risultati ottenuti e i limiti emersi suggeriscono diverse direzioni per ampliare il lavoro svolto. La prima estensione riguarda il completamento della regola clinica ABCD. L'attuale classificazione, basata unicamente su metriche geometriche, potrebbe essere ottimizzata introducendo metriche cromatiche e descrittori riguardanti la texture della lesione cutanea. Come dimostrato in letteratura da Garnavi et al. [11], l'analisi combinata delle irregolarità del bordo con le caratteristiche di texture consente di aumentare l'accuratezza nella distinzione tra nevi e melanomi. In secondo luogo, per rendere l'intera pipeline autonoma dall'inizio alla fine, risulterebbe fondamentale sviluppare un modulo di segmentazione automatica efficace. In tal caso, l'elaborazione dell'immagine grezza potrebbe articolarsi in una fase preliminare di rimozione di peli e artefatti superficiali mediante algoritmi dedicati di inpainting<sup>2</sup>, come il noto algoritmo *DullRazor* [16]. Su queste immagini pulite sarà poi possibile addestrare reti neurali dedicate alla segmentazione, superando così la dipendenza dalle maschere

<sup>1</sup>Il fenomeno del *data leakage* (o dispersione di dati) avviene quando il modello viene influenzato, direttamente o indirettamente, da informazioni appartenenti al set di test durante la fase di preparazione o addestramento, falsando la valutazione delle reali capacità di generalizzazione.

<sup>2</sup>L'*image inpainting* è una tecnica di elaborazione digitale delle immagini volta a ricostruire o sostituire porzioni deteriorate, mancanti o occluse di un'immagine (come i peli cutanei sovrapposti alla lesione), stimando i pixel mancanti a partire dall'informazione cromatica e dalla texture del tessuto sano circostante.

---

manuali fornite dal Ground Truth. Infine, un ulteriore sviluppo potrebbe riguardare la validazione dei risultati su dataset differenti, al fine di verificare la capacità delle metriche individuate di mantenere la propria efficacia anche in presenza di immagini acquisite in condizioni diverse.

# Bibliografia

- [1] Jun Ma, Yuting He, Feifei Li, Lin Han, Chen Yu You, and Bo Wang. Segment anything in medical images. *Nature Communications*, 15(1):654, 2024.
- [2] Wenjian Yao, Jiajun Bai, Wei Liao, Yuheng Chen, Mengjuan Liu, and Yao Xie. From cnn to transformer: A review of medical image segmentation models. *Journal of Imaging Informatics in Medicine*, 37:1–25, 2024.
- [3] Shun Zou, Mingya Zhang, Bingjian Fan, Zhengyi Zhou, and Xiuguo Zou. Skinmamba: A precision skin lesion segmentation architecture with cross-scale global state modeling and frequency boundary guidance. *arXiv preprint arXiv:2409.10890*, 2024.
- [4] Shun Zou, Mingya Zhang, Bingjian Fan, Zhengyi Zhou, and Xiuguo Zou. Skinmamba. <https://github.com/zs1314/SkinMamba>, 2024.
- [5] Scaler Topics. Image segmentation using grabcut. <https://www.scaler.com/topics/image-segmentation-using-grabcut/>, 2023. Ultimo accesso: Agosto 2026.
- [6] Bhakti Shetty, Ronald Fernandes, Alwyn Roshan Rodrigues, et al. Skin lesion classification of dermoscopic images using machine learning and convolutional neural network. *Scientific Reports*, 12(1):18134, 2022.
- [7] Mohamed A. Kassem, Khalid M. Hosny, Robertas Damaševičius, and Mohamed Meselhy Eltoukhy. Machine learning and deep learning methods for skin lesion classification and diagnosis: A systematic review. *Diagnostics*, 11(8), 2021.
- [8] Noel Codella, David Gutman, M Emre Celebi, Brian Helba, Michael A Marchetti, Stephen Dusza, A Kalloo, K Liopyris, N Mishra, H Kittler, et al. Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (isbi), hosted by the international skin imaging collaboration (isic). In *2018 IEEE 15th international symposium on biomedical imaging (ISBI 2018)*, pages 168–172. IEEE, 2018. arXiv preprint arXiv:1710.05006.
- [9] Seetharani Murugaiyan Jaisakthi, Palaniappan Mirunalini, and Chandrabose Aravindan. Automated skin lesion segmentation of dermoscopic images using grabcut and k-means algorithms. *IET Computer Vision*, 12(8):1088–1095, 2018.

- [10] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, volume 9351 of *Lecture Notes in Computer Science*, pages 234–241. Springer, 2015.
- [11] Rahil Garnavi, Mohammad Aldeen, and James Bailey. Computer-aided diagnosis of melanoma using border- and wavelet-based texture analysis. *IEEE Transactions on Information Technology in Biomedicine*, 16(6):1239–1252, 2012.
- [12] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [13] M Emre Celebi, Hassan A Kingravi, Burak Uddin, Hitoshi Iyatomi, Y Aydin Aslandogan, William V Stoecker, and Randy H Moss. A methodological approach to the classification of dermoscopy images. *Computerized Medical Imaging and Graphics*, 31(6):362–373, 2007.
- [14] Carsten Rother, Vladimir Kolmogorov, and Andrew Blake. "grabcut": interactive foreground extraction using iterated graph cuts. *ACM Transactions on Graphics (TOG)*, 23(3):309–314, 2004.
- [15] Gary Bradski. The opencv library. *Dr. Dobb's Journal of Software Tools*, 25(11):120, 122–125, 2000.
- [16] Tim Lee, Vincent Ng, Richard Grimes, David McLean, Andrew Coldman, and Jason Rivers. Dullrazor: A software approach to hair removal from images. *Computers in Biology and Medicine*, 27(6):533–543, 1997.
- [17] F. Nachbar, W. Stolz, T. Merkle, A. B. Cagnetta, T. Vogt, M. Landthaler, P. Bilek, O. Braun-Falco, and G. Plewig. The abcd rule of dermatoscopy. high prospective value in the diagnosis of doubtful melanocytic skin lesions. *Journal of the American Academy of Dermatology*, 30(4):551–559, 1994.

# Ringraziamenti

Vorrei ringraziare innanzitutto la mia relatrice, la professoressa Federica Baccini, per la costante disponibilità e il prezioso aiuto.

Grazie a mamma e papà per avermi supportata in questo percorso in tutti i modi possibili. Anche se non capivate nulla di quello che ripetevo, eravate sempre pronti ad ascoltarmi quando ne avevo bisogno. Il primo anno di università è stato uno dei momenti più difficili per me, ma voi eravate sempre lì al mio fianco per farmi sentire abbastanza. È bello guardare in alto, a volte, e trovare qualcuno che porta un po' del tuo peso.

Grazie anche ai miei nonni: a tutti, a quelli che ci sono ancora e a quelli che non ci sono più. Grazie a nonno Ugo e a nonna Maria; sono sicura che senza il primo computer assemblato da nonno Ugo non avrei mai sviluppato questa passione. Grazie a nonno Celestino che, se fosse stato qui, probabilmente mi avrebbe accompagnata ad ogni singolo esame; e a nonna Tilde che, quando è stata a casa con noi, mi ha ascoltata ripetere qualsiasi materia, da Cyber Security in inglese a Calcolo Scientifico, ridendo ogni volta che nominavo la lettera "sigma tilde".

Grazie a Luca, che è stato fondamentale in ogni singolo giorno di questa triennale. Pronto a sostenermi dalle cose più sciocche a quelle più importanti: durante il primo anno, quando non riuscivo a superare gli esami e l'ansia di sentirmi indietro prendeva il sopravvento, mi hai sempre confortata, mettendoti a spiegarmi argomenti che non avevi mai affrontato. Ogni sera prima di un esame eri lì pronto a darmi la carica. Sei stato fondamentale anche nella parte sperimentale di questa tesi: mi hai spronata a cercare sempre soluzioni e, quando mi bloccavo, ti mettevi lì ad aiutarmi. Ora inizierò un nuovo percorso: sai già quanto sia agitata per gli esami in inglese, ma comincio a essere più serena perché so che ogni sfida la affrontiamo insieme.

Grazie a Gabriella, Rosario e Matteo che, come una seconda famiglia, hanno gioito ad ogni mio traguardo, dalla maturità alla laurea, ascoltando con pazienza tutti i miei racconti.

Grazie a Cristiano, il mio terzo fratellino, con cui posso sempre condividere i miei interessi.

Grazie ad Eleonora: compagna di treno, di studio, di parcheggi e persino di compleanno, ma soprattutto amica. Grazie perché con te mi sono sempre sentita libera

di essere me stessa. La cosa che più mi mancherà di questa triennale sarà proprio condividere le giornate con te, a partire dalle nostre sventure mattutine.

Grazie a Mariagiusti, che durante il primo anno ha sempre trovato il consiglio giusto dopo ogni bocciatura ad Algebra. Mi mancheranno le nostre disperate sessioni di studio in videochiamata.

Grazie a Manuela che, anche se ci siamo riavvicinate in quest'ultimo anno, c'è sempre stata per ogni pausa studio su Dead by Daylight e per ascoltarmi ripetere argomenti di cui non sapeva nulla. Grazie per avermi regalato momenti di leggerezza quando la sessione si faceva troppo pesante.

Grazie infine a Paffi che, acciambellata sulle mie gambe e troppo spesso sopra la tastiera, ha studiato insieme a me ogni singolo esame.